

Vorlesungsmitschrift

Höhere Algorithmik

gelesen von Prof. Dr. Günter Rote

Tobias Höppner

Wintersemester 2014/2015

Inhaltsverzeichnis

1 Einführung (Vorlesung 1 am 17.10.)	1
1.1 Organisatorisches	1
1.2 Kuchen teilen	1
1.2.1 1. Algorithmus (für 2 Personen)	1
1.2.2 2. Algorithmus (für 3 Personen)	1
1.2.3 3. Teilen und Trimmen	2
1.2.4 4. Teilen mit bewegtem Messer	2
1.2.5 5. Simuliertes bewegtes Messer	2
1.2.6 6. Simuliertes Messer + Zufall	2
1.2.7 7. Divide & Conquer	3
1.2.8 8. Divide & Conquer + Zufall	3
2 Einführung Teil 2 (Vorlesung 2 am 20.10.)	4
2.1 Ziele der Vorlesung	4
2.2 Rechnermodelle	4
2.2.1 Turing-Maschine	4
2.2.2 Registermaschine (RAM - random access machine)	4
2.2.3 Berechnung der Laufzeit	5
2.3 Laufzeit eines Algorithmus	6
3 Rechnermodelle (Fortsetzung) (Vorlesung 3 am 24.10.)	7
3.1 Warum nicht die Turingmaschine?	7
3.2 Elementare Operationen	7
3.3 Teile und Herrsche	8
3.3.1 Beispiel A: Quicksort	8
3.3.2 Beispiel B: Mergesort (Sortieren durch Verschmelzen)	8
3.3.3 Analysemöglichkeiten	8
4 Rekursion (Fortsetzung) (Vorlesung 4 am 31.10.)	10
4.1 Motivation Master-Theorem	10
4.2 Master-Theorem für divide and conquer-Rekursion	10
4.2.1 Bemerkungen	11
4.3 Beweis: Master-Theorem	11
5 Master Theorem (Fortsetzung) (Vorlesung 6 am 3.11.)	13
5.1 Beweis Fortsetzung	13
5.2 Zählen von Fehlständen (Inversion)	14
5.2.1 Divide and Conquer - oder - Warum Mergesort so wichtig ist!	14
5.2.2 Variante	14
5.2.3 Laufzeit	15

6	Median (Vorlesung 7 am 7.11.)	16
6.1	Bestimmung des k-kleinsten Elements (Medians)	16
6.2	Quickselect	16
6.2.1	Laufzeit	16
6.3	randomisiertes Quickselect	17
6.3.1	Laufzeit	17
6.4	Quickselect nach Blum, Floyd, Pratt, Rivest, Tarjan (1973)	17
6.4.1	Laufzeit	18

1 Einführung (Vorlesung 1 am 17.10.)

1.1 Organisatorisches

Mitschrift wird von Studenten erstellt.

Korrekturfarbe für Gummipunkte: Grün!

Voraussetzungen

- O-Notation
- Turing-Maschine
- Sortieralgorithmen
- Schubfachprinzip
- Gauß-Nummer
- Harmonische Reihe

1.2 Kuchen teilen

Problem: Ein Kuchen soll unter zwei Personen aufgeteilt werden.

Zwei Lösungsideen:

- perfektes Teilen
- einer teilt den Kuchen und der andere sucht sich eine Hälfte aus.

Was passiert, wenn jemand die Teile des Kuchens unterschiedlich bewertet? (z.B. Kirsche auf einer Seite, viel Sahne auf der anderen Seite)

Perfektes teilen bedeutet, dass jemand *für sich* perfekt teilt. (nach seinem Maßstab)

Ziel: Fairness Jeder will $\frac{1}{n}$ des Kuchens nach ihrem Maßstab. ($n = \# \text{Personen}$)

1.2.1 1. Algorithmus (für 2 Personen)

1. Erste teilt
2. Zweite sucht aus

Der Algorithmus ist toll, aber es gibt zu viele Schritte. Daher wollen wir den Algorithmus verbessern.

Ziel: möglichst wenige Schritte.

1.2.2 2. Algorithmus (für 3 Personen)

Anton, Berta und Clara:

1. Anton teilt $\frac{1}{3} | \frac{2}{3}$
2. Berta teilt $\frac{2}{3} | \frac{2}{3}$
3. Clara sucht aus.
4. Anton sucht aus.

Fall 1: Clara nimmt eines der rechten Stücke \Rightarrow Anton nimmt linkes Stück.


Fall 2: Clara nimmt linkes Stück.

Schubfachprinzip: eines der rechten Stücke ist mindestens $\frac{1}{3}$

5. Berta):

1.2.3 3. Teilen und Trimmen

1. Anton teilt:



2. Berta:

Fall 1: Berta denkt $x \leq \frac{1}{3}$

Fall 2: Berta denkt $x > \frac{1}{3} \Rightarrow$ Trimmen

3. Clara darf sich entscheiden:

Fall 1: will x^* dann Algorithmus 1. für den Rest

Fall 2: will x^* nicht.

$\Rightarrow w^* \geq \frac{2}{3}$ für Clara und Anton

1.2.4 4. Teilen mit bewegtem Messer

Man nimmt ein Messer und jede Person sagt einfach Stop, wenn die *perfekte Wahl* für die Person getroffen ist.

#Schritte = $n - 1$

1.2.5 5. Simuliertes bewegtes Messer

- Jeder macht bei $\frac{1}{n}$ eine Markierung
 - der/die Linkeste bekommt das Stück
- #Schritte = $n + (n - 1) + \dots + 3 + 2 = \theta(n^2)$ (Gauß-Nummer)

1.2.6 6. Simuliertes Messer + Zufall

Wie 5., aber

1. Reihenfolge zufällig
2. nur neue Linkeste Markierung werden gemacht

3. $T(n) = \# \text{erwartete Markierungen}$

$$= \underbrace{\frac{1}{n}}_{\text{Erwartete Anzahl der letzten Markierung}} + \underbrace{T(n-1)}_{\text{Erwartete Anzahl von Markierungen aller Anderen.}}$$

4. $T(n) = 1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \dots + \frac{1}{n} = \theta(\log n)$ (harmonische Reihe)

5. Gesamtlaufzeit $\leq n * O(\log n) = O(n * \log n)$

1.2.7 7. Divide & Conquer

n Personen

n Markierungen bei $\frac{k}{n}$

#Schritte im Worst Case $T(n) = n + 2$

1.2.8 8. Divide & Conquer + Zufall

(erwartete) Laufzeit pro Teilen $\theta(\log n)$ also insgesamt $\theta(n)$

2 Einführung Teil 2 (Vorlesung 2 am 20.10.)

2.1 Ziele der Vorlesung

- Algorithmen nach den wichtigsten Entwurfsprinzipien entwerfen:
 - Devide and Conquer
 - dynamisches Programmieren
 - bound and bound
 - greedy-Algorithmen
- Algorithmen mit Analysetechniken analysieren im Bezug auf Laufzeit und Speicherbedarf (Stromverbrauch)
 - randomisierte Analyse
 - amortisierte randomisierte Analyse
 - Rekursionsgleichungen
- Vergleich und Beurteilung von Algorithmen nach Einsatzzweck
- Theorie der NP Vollständigkeit verstehen und einfache Vollständigkeitsbeweise führen

(Stromverbrauch ist zunehmend wichtig, aber nicht Teil der Vorlesung. Allgemein sind Algorithmen mit weniger Laufzeit besser.)

2.2 Rechnermodelle

2.2.1 Turing-Maschine

Eine Turing-Maschine ist ein theoretisches Modell. Es handelt sich um ein unendliches Band mit Symbolen aus einem endlichen Alphabet mit endlichem Zustandsraum. In jedem Schritt wird ein Symbol gelesen, das Band entsprechend der Eingabe beschrieben und der Zustand verändert. Prinzipiell ist alles mit einer Turing-Maschine berechenbar, jedoch teilweise sehr umständlich, weil immer nur ein Symbol gelesen werden kann.

2.2.2 Registermaschine (RAM - random access machine)

Eine RAM funktioniert nach einem ähnlichen Prinzip wie moderne Rechner arbeiten. Es gibt eine potentiell unendliche (unbeschränkte) Anzahl von Registern R_0, R_1, R_2, \dots wobei jedes Register eine ganze Zahl enthalten kann. Die Programmiersprache ist ähnlich wie Assembler.

RAM ist auch als random access memory als Arbeitsspeicher bekannt

1. Befehle

Zuweisung $R_4 = R_{17}$

Rechenbefehl $R_1 = R_2 + R_3$

$R_1 = R_2 - R_3$

$R_1 = R_2 * R_3$

$R_1 = R_2 / R_3$

Operanden der Befehle

1. Register R_{17}
2. direkte Operanden (Zahlen) 250
3. indirekte Adressen: (R_1)

den Inhalt des Registers, dessen Nummer in Register R_1 steht.

2. Sprünge

```
1 GOTO x
2 IF Ri = 0 THEN GOTO x
3
4 GZ R1, label ;if R1 is greater 0, goto label
```

Es sind nur die drei
Vergleichsoperationen
GLZ: < 0 , GGZ: >
0 , GZ: = 0
erlaubt!

x ist eine Sprungmarke im Programm.

```
1 loop:
2   \\ some commands
3   GOTO loop
```

3. HALT

Ein Programm endet immer mit **HALT**

Ein- und Ausgabe

Eingabe: R0 = n= die Länge der Eingabe R1, R2, ... Rn. Alle andere Zellen sind auf 0 initialisiert.

Ausgabe steht am Ende im Speicher!

2.2.3 Berechnung der Laufzeit

a) Einheitskostenmaß (EKM)

Jede Operation dauert eine Zeiteinheit.

unfair, weil es Operationen gibt, die offensichtlich komplizierter sind.

b) logarithmisches Kostenmaß (LKM)

Laufzeit = Summe der Längen aller vorkommenden Adressen und Operanden.

$$l(x) = \lfloor \log_2 \max\{|x|, 1\} \rfloor + 1$$

$$\begin{aligned} R2 &= (R0) + 250 \\ \dots \text{Kosten} &= l(2) + l(0) + \underbrace{l(R0)}_{\text{Adresse}} + \underbrace{l((R0))}_{\text{Operand}} + \underbrace{l(250)}_{\text{Operanden}} \end{aligned}$$

Das LKM ist gerechter, als das EKM.

Im EKM kann man schwindeln:

Operationen auf langen Daten können in einem Schritt erledigt werden.

Andererseits ist das EKM näher an einem tatsächlichen Prozessor. Sofern die Operanden in ein Wort eines konventionellen Speichers (64 Bit) passen.

Abschätzung: $LKM \leq O(EKM \cdot l(\text{längster vorkommender Operand oder Adresse}))$

Wenn die größten vorkommenden Zahlen nicht zu groß sind, dann ist das EKM realistisch.

LKM ist fairer, wenn es um sehr unterschiedliche Operanden geht (verschieden lang)

2.3 Laufzeit eines Algorithmus

Man muss den möglichen Eingaben eine Länge zuordnen.

x .. Eingabe $L(x)$

Bsp. n Zahlen x_1, x_2, \dots, x_n sortieren: $L = n$

Bsp. Multiplikation von langen Zahlen x, y : $L = \#$ Bits in der Eingabe.

Bsp. Lösen eines linearen Gleichungssystems: $Ax = b$ $A \in \mathbb{Z}^{n \times n}$ $b \in \mathbb{Z}^n$ $x \in \mathbb{Q}^n$

Länge der Eingabe: n^2

Gauß-Elimination $O(n^3)$ Zeit, erfordert Rechnen mit rationalen Zahlen.

Man kann Zeigen, dass die Länge der Zähler und Nenner in den Zwischenergebnissen höchstens n -Mal ($\leq n$) ist, wenn man Brüche immer kürzt.

Laufzeit im LKM: $O(n^4, l(\text{größte Eingabezahl}))$

*Tendenziell
kompliziertes Beispiel,
um zu illustrieren, dass
LKM nicht immer
leicht zu berechnen ist.*

Was ist die Laufzeit eines Algorithmus?

$T(x)$ = Laufzeit des Algorithmus bei Eingabe x

$$(Analyse\text{im}\text{schlimmsten}\text{Fall}).T(n) = \max\{T(x) | L(x) = n\}$$

Andere Möglichkeiten

Analyse im Durchschnitt, Erwartungswert der Laufzeit

Benötigt eine Wahrscheinlichkeitsverteilung auf der Menge der Eingaben.

3 Rechnermodelle (Fortsetzung) (Vorlesung 3 am 24.10.)

3.1 Warum nicht die Turingmaschine?

Die Registermaschine ist näher am heutigen Rechnermodell. Die Turingmaschine ist viel primitiver.

Satz:

- a) Ein Algorithmus, der auf einer Registermaschine Laufzeit $T(n)$ im logarithmischen Kosteneinheitsmaß hat, kann auf einer Turingmaschine in Laufzeit $O((T(n))^3)$ simuliert werden.
- b) Ein Algorithmus mit Laufzeit $U(n)$ auf einer Turingmaschine kann mit Laufzeit $O(U(n) \log U(n))$ auf einer Registermaschine im LKM simuliert werden.

zu b) In Zeit $U(n)$ kann die Maschine höchstens die Felder $-U(n) \dots + U(n)$ beschreiben. Adressen sind durch $2U(n)$ beschränkt. Jeden Schritt der TM kann in konstant vielen Operationen der Registermaschine simuliert werden.
 $\rightarrow O(\log U(n))$

zu a) Speicherinhalt auf dem Band notieren.

i : (Inhalt von Register i). $(i+1)$: Inhalt von Register $(i+1)$

Register mit Inhalt 0 können weggelassen werden. Register werden in natürlicher Reihenfolge aufgeschrieben. Alle Zahlen binär oder dezimal (nach Belieben).

Die Länge des Bandes $= L$ ist durch $T(n)$ beschränkt.

Jede Adresse, jede Registereinheit wurde bei der letzten Benutzung in voller Länge bei $T(n)$ berücksichtigt.

3.2 Elementare Operationen

1. Adresse im Speicher suchen; (Adresse steht im linken Zwischenbereich)
2. entsprechenden Inhalt zwischen Speicher und Zwischenbereich übertragen
3. Rechenoperationen im Zwischenbereich

₁ R2 = (R17)

Jede Stelle, die verglichen wird, erfordert im schlimmsten Fall ein Wandern über das gesamte Band.

Operation 1 dauert $O(L^2)$ Schritte, wobei L die Länge des Bandes ist.

Operation 2 ist ähnlich. Gegebenenfalls muss man den rechten Teil des Bandinhalts verschieben (Um eine Stelle verschieben dauert $O(L)$ Zeit, $\leq O(L^2)$ insgesamt).

Operation 3 $\leq O(L^2)$

$O(L^2)$ für 1 Schritt der Registermaschine $= O(T(n))^2$

3.3 Teile und Herrsche

(eng. divide and conquer) (lat. divide et impera)

1. Zerlege das Problem P in Teilprobleme P_1, P_2, \dots, P_k (typischerweise $k = 2$)
2. Löse die Teilprobleme rekursiv.
3. Füge die Teillösung zur Lösung von P zusammen.

3.3.1 Beispiel A: Quicksort

1. Wahl eines Pivotelementes a :
Zerlegung in Elemente $\underbrace{\leq a}_{\text{Teilproblem}}, = a, > a$
3. Teilfolgen aneinanderhängen.

Bei Quicksort ist der erste Schritt aufwändiger, bei Mergesort der letzte Schritt.

3.3.2 Beispiel B: Mergesort (Sortieren durch Verschmelzen)

1. Zerlegung in 2 gleich große Teile
3. Verschmelzen der beiden sortierten Teillisten.

Laufzeit $T(n) = T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + \Theta(n)$

n gerade $T(n) = 2T(\frac{n}{2}) + \Theta(n)$

Lösung $T(n) = O(n \log n)$

3.3.3 Analysemöglichkeiten

- I. Lösung erraten und durch vollständige Induktion beweisen.
- II. Wiederholtes einsetzen auf der rechten Seite:

$$T(n) \leq 2T\left(\frac{n}{2}\right) + cn \quad (c > 0)$$

$$T\left(\frac{n}{2}\right) \leq 2T\left(\frac{n}{4}\right) + c * \frac{n}{2}$$

$$T(n) \leq 2\left(2T\left(\frac{n}{4}\right) + c\frac{n}{2}\right) + cn$$

$$= 4 \underbrace{T\left(\frac{n}{4}\right)}_{=2T\left(\frac{n}{8}\right)+c\frac{n}{4}} + cn + cn$$

$$\leq 8T\left(\frac{n}{8}\right) + cn + cn + cn$$

$$\leq 2^k T\left(\frac{n}{2^k}\right) + k.c.n$$

Annahme $n = 2^l$ ist eine Zweierpotenz $l = \log_2 n$

$$\begin{aligned} T(n) &= \underbrace{2^l}_n \underbrace{T(1)}_{\text{konst.}} + \underbrace{l}_{\log_2 n} \cdot c \cdot n = O(n \log n) \\ &= O(n) + O(n \log n) \end{aligned}$$

nur gültig für Zweierpotenzen.

Möglichkeit a) n auf die nächste $n' = 2^l$ aufrunden.

$$n \leq n' < 2n$$

Sortieren von n Elementen kann nicht länger dauern als Sortieren von n' Elementen.
(zu beweisen! z.B. mit vollst. Induktion anhand der Rekursion)

$$T(n) \leq T(n') = O(n' \log n') = O(2n \cdot \log(2n)) = O(n \log n) \checkmark$$

Möglichkeit b) Als Inspiration, um auf die Vermutung $O(n \log n)$ zu bekommen. Beweis mit Methode I.

III. Rekursionsbaum $\lfloor \frac{\lfloor \frac{n}{2} \rfloor}{2} \rfloor = \lfloor \frac{n}{4} \rfloor$ Laufzeit: 2^l Probleme konstanter Größe. $T(1), T(2) \leq c'$

$$\text{Ebene 0 : } \leq \Theta(n)$$

$$\text{Ebene 1 : } \leq 2\Theta(\lceil \frac{n}{2} \rceil)$$

$$\text{Ebene 2 : } \leq 4\Theta(\lceil \frac{n}{4} \rceil)$$

$$\Theta(n) \leq c \cdot n$$

$$\begin{aligned} \text{Summe} &\leq cn + 2c \lceil \frac{n}{2} \rceil + 4c \lceil \frac{n}{4} \rceil + \dots + 2^{l-1} c \lceil \frac{n}{2^{l-1}} \rceil + 2^l c' \\ &\leq cn + 2c(\frac{n}{2} + 1) + 4c(\frac{n}{4} + 1) + \dots \\ &= \underbrace{cn + cn + \dots + cn}_{l\text{-mal}} + \underbrace{2c + 4c + 8c + \dots + 2^{l-1}c}_{(2^l - 2)c} + 2^l c' \end{aligned}$$

4 Rekursion (Fortsetzung) (Vorlesung 4 am 31.10.)

4.1 Motivation Master-Theorem

$$T(n) = \underbrace{T\left(\frac{n}{b}\right)}_{T(\lfloor \frac{n}{b} \rfloor) + \dots + T(\lceil \frac{n}{b} \rceil)} * a + f(n)$$

Für Probleme $\leq n_0$ wird das Problem irgendwie direkt gelöst.

Startbedingung: $1 \leq T(n) \leq M$ für $n \leq n_0$

In der Praxis muss man natürlich irgendwann das n_0 ausrechnen und kann nicht beliebig lange aufteilen.

Die Konstanten $a \geq 1$ und $b > 1$ müssen erfüllt sein und außerdem müssen wir fordern:

$$\begin{aligned} \lceil \frac{n}{b} \rceil &\leq n - 1 \text{ für } n > n_0 \\ \Leftrightarrow \frac{n}{b} &\leq n - 1 \\ n(1 - \frac{1}{b}) &\geq 1 \\ n &\geq \frac{b}{b-1} \\ \Rightarrow n_0 &\geq \frac{b}{b-1} \end{aligned}$$

sonst werden die Probleme nicht kleiner und die Rekursion kann nicht gelöst werden.

$$n \log_b n \text{ Elemente} \begin{cases} 1 \text{ Problem der Größe } n & \text{Aufwand } 1f(n)n^k \text{ Annahme } f(n) = n^k \\ 2 \text{ Probleme der Größe } \frac{n}{b} & \text{Aufwand } a * f(\frac{n}{b})a(\frac{n}{b})^k \\ 3 \text{ Probleme der Größe } \frac{n}{b^2} & \text{Aufwand } a^2 * f(\frac{n}{b^2})a^2(\frac{n}{b})^k \\ \vdots & \vdots \end{cases}$$

Beispiel: Mergesort

$$\begin{aligned} a &= b = 2 \\ \gamma &= \log_2 2 = 1 \end{aligned}$$

4.2 Master-Theorem für divide and conquer-Rekursion

$$\begin{aligned} a &\geq 1, b > 1, M, n_0 \geq 1 (\frac{n_0}{b} \leq n_0 - 1) \\ f(n), T(n) &\text{Funktionen auf den natürlichen Zahlen} \\ f(n) &\geq 0 \end{aligned}$$

Es gelten die Rekursionsbedingungen

$$\begin{aligned} T(n) &\leq aT(\lceil \frac{n}{b} \rceil) + f(n) & (n > n_0) \\ T(n) &\geq aT(\lfloor \frac{n}{b} \rfloor) + f(n) & (n > n_0) \\ 1 &\leq T(n) \leq M \end{aligned}$$

Dann definieren wir den kritischen Exponenten

$$n = \log a > 0$$

(-) Wenn $f(n) = \mathcal{O}(n^{\gamma-\epsilon})$ für ein $\epsilon > 0$, dann
 $T(n) = \Theta(n^\gamma)$

(=) Wenn $f(n) = \Theta(n^\gamma)$ ist, dann
 $T(n) = \Theta(n^\gamma \log n)$

(+) Wenn $f(n) = \Theta(n^{\gamma+\epsilon})$ für ein $\epsilon > 0$ ist oder wenn die Regularitätsbedingung erfüllt ist
 $\exists c < 1$:

(*) $a \cdot f(\lceil \frac{n}{b} \rceil) < c \cdot f(n)$ für alle $n > n_0$
dann gilt: $T(n) = \Theta(f(n))$

4.2.1 Bemerkungen

1. Wenn f monoton ist, dann gelten die Schlussfolgerungen auch für beliebig gemischtes Auf- und Abrunden.
2. Mit (*) kann man auch Funktionen wie $f(n) = 2^n$ oder $f(n) = 2^{\sqrt{n}}$ erfassen.
3. $\Omega(n^{\gamma+\epsilon})$ im Fall (+) reicht leider nicht.
4. $f(n) = n \log n, \gamma = 1$ wird nicht erfasst.

4.3 Beweis: Master-Theorem

a.) Wir betrachten die oberen Schranken für die Fälle (-) und (=)

(a) Ersetze $f(n)$ durch die oberen Schranke $u \cdot n^k$
 $f(n) \leq u \cdot n^k$ Finde eine Funktion $P(n)$ mit $(***) P(n) \geq aP(\lceil \frac{n}{b} \rceil) + u n^k$ für
 $n \geq n_0$
und $P(n) \geq M$ für $n \geq n_0$
Dann ergibt sich durch vollständige Induktion: $T(n) \leq P(n)$
Basis: ($n \leq n_0$)

$$\begin{aligned} T(n) &\leq aT(\lceil \frac{n}{b} \rceil) + f(n) \leq (\text{I.V.}) \\ &\leq aP(\lceil \frac{n}{b} \rceil) + f(n) \\ &\leq aP(\lceil \frac{n}{b} \rceil) + u n^k \leq P(n) \end{aligned}$$

(b) Verschiebung des Definitionsbereiches, um $\lceil \rceil$ los zu werden.

$v = \frac{b}{b-1} \Rightarrow -\frac{v}{b} = 1 - v$
 $P(n) = T'(n - v)$ bzw. $T'(n) = P(n + v)$
 T' ist jetzt auf $\mathbb{R}_{>0}$ definiert.
Wir bestimmen dann T' so, dass
 $(**) T'(n) = aT'(\frac{n}{b}) + u' n^k$ (u ist eine Konstante)

Behauptung: aus (**) folgt (***), falls T' monoton wächst

$$\begin{aligned}
 \underbrace{P(n)} &\geq aP(\lceil \frac{n}{b} \rceil) + un^k \\
 \text{L.S.} = P(n) &= T'(n-v) = aT'(\frac{n}{b} - \frac{v}{b}) + u'(n-v)^k \\
 \text{R.S.} &= aP(\lceil \frac{n}{b} \rceil) + un^k \\
 &= aT'(\lceil \frac{n}{b} \rceil - v) + un^k \\
 &< aT'(\frac{n}{b} + 1 - v) + un^k \\
 &= aT'(\frac{n-v}{b}) + un^k
 \end{aligned}$$

Jetzt müssen wir nur noch u' so wählen, dass $u'(n-v)^k \geq un^k$ für $n \geq n_0 u' \geq u \frac{n_0^k}{(n_0-v)^k}$

Lösen von (**) durch Ansatz:

Fall (-) $k = \gamma - \epsilon : T'(n) = Dn^\gamma + En^k$ Einsetzen in (**)

$$\begin{aligned}
 Dn^\gamma + En^k &= aD(\frac{n}{b})^\gamma + aE(\frac{n}{b})^k + u'n^k \\
 &= Dn^\gamma \underbrace{\frac{a}{b^\gamma}}_1 + n^k(aE\frac{1}{b^k} + u')
 \end{aligned}$$

$$\begin{aligned}
 E(1 - \frac{a}{b^k}) &= u', E = \frac{u'}{1 - \frac{a}{b^k}} \\
 E(1 - \frac{b^\gamma}{b^{\gamma-\epsilon}}) &= u' \\
 E(1 - b^\epsilon) &= u' \\
 \underline{E} &= \frac{-u'}{b^\epsilon - 1} < 0
 \end{aligned}$$

D ist noch frei: Wähle D groß genug, dass $P(n) = T'(n-v) = D(n-v)^\gamma + E(n-v)^k \geq M$ für $n \leq n_0$ ist.

Fall (=)

$$\begin{aligned}
 T'(n) &= Dn^\gamma + En^\gamma \log_b n \\
 \dots \Rightarrow E &= u', D \text{ bleibt frei. - } D \text{ groß genug.}
 \end{aligned}$$

Ergebnis im Fall (-) $T(n) \leq D(n-v)^\gamma + E(n-v)^{\gamma-k} = \mathcal{O}(\backslash^\gamma)$

Ergebnis im Fall (=) $= \mathcal{O}(\backslash^\gamma \log \frac{1}{\gamma})$

5 Master Theorem (Fortsetzung) (Vorlesung 6 am 3.11.)

5.1 Beweis Fortsetzung

Fall (+)

$$T(n) \leq T(\lceil \frac{n}{b} \rceil) + f(n)$$

$$T(n) \geq T(\lfloor \frac{n}{b} \rfloor) + f(n)$$

$$f(n) = \Theta(n^{\gamma+\epsilon})$$

$$\gamma = \log_b a$$

$$\text{oder: } \forall n > n_0 : a \cdot f(\lceil \frac{n}{b} \rceil) < c \cdot f(n)$$

$c < 1$ ist eine Konstante

$$\Rightarrow T(n) = \Theta(f(n))$$

Beweis (Induktion)

untere Schranke $T(n) \geq f(n)$ (aus der Rekursion) $\Rightarrow T(n) = \Omega(f(n))$

obere Schranke: Ansatz: $T(n) \leq D \cdot f(n)$

Versuch eines Beweises durch Induktion.

n_0 groß genug machen, dass $\frac{n_0}{b} \leq n_0 - 1 \Rightarrow \frac{n}{b} \leq n - 1 \forall n \geq n_0$

$\Rightarrow \lceil \frac{n}{b} \rceil < n$ Induktion kann funktionieren.

Induktionsschritt: $n \geq n_0$ für $i < n$ sei $T(i) \leq D \cdot f(i)$ schon bewiesen.

$$\begin{aligned} T(n) &\leq aT(\lceil \frac{n}{b} \rceil) + f(n) \\ &\leq a \cdot D \cdot f(\lceil \frac{n}{b} \rceil) + f(n) \quad \text{nach I.V.} \\ &\leq D \cdot c f(n) + f(n) \quad \text{Regularitätsbedingung} \\ &\leq D \cdot f(n) \end{aligned}$$

$$\begin{aligned} &\underbrace{Dc + 1 \leq D}_{\text{notwendig}} \\ &\Leftrightarrow D(1 - c) \Leftrightarrow D \geq \frac{1}{1 - c} \end{aligned}$$

Induktionsbasis: Wähle D groß genug, dass $T(i) \leq Df(i)$ für $i = 1, 2, \dots, n_0 - 1$ gilt.

(Voraussetzung: $f(i) > 0$)

$$D = \max\left\{\frac{T(1)}{f(1)}, \frac{T(2)}{f(2)}, \dots, \frac{T(n_0)}{f(n_0)}, \frac{1}{1-c}\right\}$$

2. Fall: $f(n) = \Theta(n^{\gamma+\epsilon}), \epsilon > 0$

Obere Schranke (a) Ersetze $f(n)$ durch $u \cdot n^{\gamma+\epsilon}$

Beweise, dass $f(n) = u \cdot n^{\gamma+\epsilon}$ die Regularitätsbedingung erfüllt. (zunächst ohne Aufrunden, weil leichter).

$$a \cdot f(\frac{n}{b}) < c \cdot f(n) \text{ L.S. } = a \cdot u \cdot (\frac{n}{b})^{\gamma+\epsilon} = \frac{a \cdot u \cdot n^{\gamma+\epsilon}}{b^{\gamma+\epsilon}}$$

$$\text{R.S. } = c \cdot u \cdot n^{\gamma+\epsilon}$$

n_0 so groß wählen, dass $\frac{(\frac{n}{b}+1)^{\gamma+\epsilon}}{(\frac{n}{b})^{\gamma+\epsilon}}$ nahe genug bei 1 ist, sodass die L.S. immer noch $< cf(n)$ ist.

$\Leftrightarrow (1 + \frac{b}{n_0})^{\gamma+\epsilon} < b^\epsilon \leftarrow n_0$ groß genug wählen.

5.2 Zählen von Fehlständen (Inversion)

Ein Fehlstand ist ein Paar $a_i > a_j$ mit $i > j$.

$(7, 3, 17, 12, 16, 20) = (a_1, \dots, a_n)$

$0 \leq \# \text{Fehlstände} \leq \binom{n}{2}$

5.2.1 Divide and Conquer - oder - Warum Mergesort so wichtig ist!

Fehlstände können zwischen linker und rechter Hälfte leicht bestimmt werden, wenn man die beiden sortierten Listen verschmelzt.

$(15610)(2479)$ Anzahl der Fehlstände = Anzahl der Fehlstände links + Anzahl der Fehlstände rechts

$F((a_1, \dots, a_n) \dots$ Ausgabe: Sortierte Liste $(b_1, \dots, b_n), k$ wobei $k = \# \text{Fehlstände}$

```

1 if n=0: return (a_1), 0
2 n' = \lfloor \frac{n}{2} \rfloor; n'' = n - n'
3 (b_1, \dots, b_n), F_L = F(a_1, \dots, a_{n'})
4 (c_1, \dots, c_{n''}), F_R = F(a_{n'+1}, \dots, a_n)
5 k = F_L + F_R
6 i = j = 1;
7 for l = 1, 2, \dots, n
8   if (b_i \leq c_j or j = n'' + 1) and i \leq n'
9     d_l = b_i; k = k + (j - 1)
10    i ++
11  else
12    d_l = c_j
13    j ++
14  return (d_1, \dots, d_n), k

```

5.2.2 Variante

Länge des Fehlstands ist $j - i (a_i > a_j, j > i)$

p = Gesamtlänge alle Fehlstände; wir brauchen zusätzlich zu jedem Element die Position in der ursprünglichen Liste.

Eingabe: $a_1, \dots, a_n \dots$ Ausgabe ist $(b_1, \dots, b_n), (q_1, \dots, q_n), k, p$

q_i ist die Position von b_i in der Liste $(a_1, \dots, a_n) \dots (q_i)$ ist eine Permutation von $(1, \dots, n)$

Rekursive Aufrufe...

$(b_1, \dots, b_n), (q_1, \dots, q_n'), F_L, P_L = \text{rekursiv}(c_1, \dots, c_n), (r_1, \dots, r_n''), F_R, P_R =$

```

1 i = j = 1
2 for l = 1, \dots, n
3   if i <= n' and (j = n'' + 1 or b_i \leq c_j)
4     d_l = b_i
5     s_l = q_i
6     k = k + j - 1
7     // eckige klammer rechts neben die oberen 3 ausdrücken
8     p = p + (j - 1) (n' - q_i) + 1
9     // ende
10    i ++
11  else
12    d_l = c_j
13    s_l = r_j + n'

```

```

14    // eckige Klammer rechts neben der beiden oberen ausdrücke:
15    T = T + r_j
16    // ende
17    j ++
18    return (d_1, ..., d_n)(s_1, ..., s_n), k, p

```

5.2.3 Laufzeit

Nach Master-Theorem:

$$T(n) = T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + \Theta(\underbrace{n}_{n^\gamma(=)})$$

$$a = 2, b = 2, \gamma = \log_2 2 = 1$$

$$T(n) = \Theta(n \log n)$$

Oft teilt das Problem auf, dass man Größen in zwei (ungefähre) gleich große Teile zerlegen möchte, einen Teil mit den kleineren Werten, und einen Teil mit den größeren Werten.

Der **Median** ($= \frac{n}{2}$) - größtes Element ist der ideale Trennungspunkt.

6 Median (Vorlesung 7 am 7.11.)

6.1 Bestimmung des k-kleinsten Elements (Medians)

Eingabe: (a_1, a_2, \dots, a_n) Liste mit Werten, $k, 1 \leq k \leq n$

Bestimme das k-kleinste Element in sortierter Reihenfolge.

Sortierte Reihenfolge $a^{(1)} \leq a^{(2)} \leq \dots \leq a^{(n)}$

Gesucht ist $a^{(k)}$; k = Stelle in der sortierten Reihenfolge heißt der **Rang** des Elements

Beispiel: $(4, 2, 1, 7, 9)$ Rang von a_4 ist 3.

Das Element, das in der Mitte steht heißt der Median.

Oft hat man versucht das Element in der Mitte zu bestimmen, in dem man alle Werte aufsummiert und dann durch die Anzahl der Werte teilt. Das Ergebnis sollte dann der Mittelwert sein.

Das Problem sind allerdings Werte, die im Verhältnis zu allen anderen deutlich größer sind (bsp. $(1, 2, 3, 4, 2, 3, 9000)$), weil sie den Mittelwert ungünstig verschieben, sodass er keinen Sinn ergibt.

Der **Median** kann wie folgt bestimmt werden:

für ungerade n

$$a_{\frac{n+1}{2}}$$

für gerade n

$$\frac{1}{2}(a_{\frac{n}{2}} + a_{\frac{n}{2}+1})$$

6.2 Quickselect

Algorithmus: Quickselect(k, l) mit $l = (a_1, \dots, a_n)$

1. Wähle Pivotelement a
2. Zähle, wie viele Elemente $<, =, > a$ sind. Der Rang von a ist zwischen $n_{<} + 1$ und $n_{<} + n_{=}$
3. **if** $k \leq n_{<}$ **then** Quickselect(k, l_{kleiner}), wobei $|l_{<}| = n_{<}$ und l_{kleiner} enthält die Elemente $< a$.
4. **if** $k > n_{<} + n_{=}$ **then** Quickselect($k - n_{<} - n_{=}, l_{\text{groesser}}$)
5. return a

6.2.1 Laufzeit

Laufzeit im schlimmsten Fall: Pivotelement immer das kleinste Element oder größte.

Liste wird nur um 1 kleiner in jeder Rekursion $\rightarrow \Theta(n^2)$

Laufzeit im besten Fall: • Rang(a) = k , keine Rekursion notwendig $\rightarrow \Theta(n)$ (GLÜCK!)

- Teilung in der Mitte: $n_{<}, n_{>} \leq \frac{n}{2} : T(n) = T(\frac{n}{2}) + \Theta(n)$ Ein bisschen Mastertheorem:

$$T(n) = 1 * T(\frac{n}{2}) + \Theta(n)$$

$$a = 1$$

$$b = 2$$

$$f(n) = \Theta(n^1) > 0$$

$$\gamma = \log_b a = 0 \rightarrow \text{Fall}(+) \Rightarrow T(n) = \Theta(f(n)) = \Theta(n)$$

Alternative (Einsetzen:)

$$T(n) = \Theta(n) + \Theta\left(\frac{n}{2}\right) + \Theta\left(\frac{n}{4}\right) \cdots = \Theta(n)$$

Der Algorithmus ist also stark davon abhängig welches Pivotelement wir wählen. Ideal wäre es den Median zu finden. Da wir aber hier versuchen den Median zu finden ist das ein Zirkelschluss. Dabei muss es nicht mal genau das Element genau in der Mitte sein, es reicht, wenn es nahe genug dran ist.

6.3 randomisiertes Quickselect

Wähle a zufällig aus der Liste.

Rang(a) ist gleich verteilt auf $1, 2, \dots, n$.

6.3.1 Laufzeit

Analyse der erwarteten Laufzeit:

Wir nennen den Aufruf von Quickselect erfolgreich, wenn:

$$\begin{aligned} n_{<} + n_{=} &= \frac{1}{4}n \\ n_{>} + n_{=} &= \frac{1}{4}n \end{aligned}$$

in der obersten Aufrufebene ist.

$$\left[\frac{1}{4}n \leq \text{rang}(a) \leq \frac{3}{4}n\right]$$

wenn (a) eindeutig ist.

Wahrscheinlichkeit(erfolgreich) $\geq \frac{1}{2}$

Bei einem erfolgreichen Aufruf wird die Liste auf höchstens $\frac{3}{4}n$ reduziert.

$T(n)$ = erwartete Laufzeit.

$$\begin{aligned} T(n) &\leq E(\#\text{Läufe bis zu einem erfolgreichen Lauf}) \cdot \mathcal{O}(n) + T\left(\frac{3}{4}n\right) \\ &= \frac{1}{p} \text{ wobei } p = \frac{1}{2} \text{ die Erfolgswahrscheinlichkeit ist.} \\ &= \leq 2 \end{aligned}$$

$$T(n) \leq T\left(\frac{3}{4}n\right) + \mathcal{O}(n) \Rightarrow T(n) = \mathcal{O}(n)$$

6.4 Quickselect nach Blum, Floyd, Pratt, Rivest, Tarjan (1973)

Deterministische Auswahl in $\mathcal{O}(n)$ Zeit.

1. Falls $n \leq n_0$, sortiere
2. Andernfalls zerlege Folge in 5er-Gruppen und bestimme in jeder Gruppe den Median $m_1, m_2, \dots, m_{\lfloor \frac{n}{5} \rfloor}$
3. Bestimme den Median m^* dieser Mediane rekursiv.
4. Wähle das Pivotelement $a := m^*$ und verfähre weiter wie bei Quickselect.

6.4.1 Laufzeit

Welche Aussagen treffen jetzt auf $n_{<} + n_{=}$ und $n_{>} + n_{=}$ zu?

$$n_{<} + n_{=} \geq 3 \frac{\lfloor \frac{n}{5} \rfloor}{2}$$

$$n_{>} + n_{=} \geq 3 \frac{\lfloor \frac{n}{5} \rfloor}{2}$$

$$\begin{aligned} n_{<} &= n - (n_{<} + n_{=}) \\ &= n - \frac{3}{2} * \lfloor \frac{n}{5} \rfloor \end{aligned}$$

Annahme $n = 5l$

$$n_{<} \leq n - 0,3 = 0,7n$$

$$n = 5l + i$$

$$|i = 0, 1, 2, 3, 4 \quad l = \lfloor \frac{n}{5} \rfloor$$

$$n_{<} \leq n - \frac{3}{2}l = n - \frac{3}{2}(\frac{n-i}{5})$$

$$= n - \frac{3}{10}n + \frac{3}{10}i$$

$$\leq \frac{7}{10}n + \frac{12}{10} \leq \frac{7}{10}n + 3$$

$$n_{<} \leq \frac{7}{10}n + 3$$

Behauptung: $T(n) = \mathcal{O}(n)$

Beweis: Annahme:

$$T(n) \leq Cn + T(\lfloor \frac{n}{5} \rfloor) + T(\lfloor 0,7n \rfloor + 3) \text{ für } n \geq 100$$

Behauptung $T(n) \leq C'n$, wenn $C' \geq 20C$ ist und C' so groß ist, dass $T(n) \leq C'n$ für $n \geq 100$ ist.

Beweis mit vollständiger Induktion: $n \geq 100$ geht!

für $n > 100$:

$$\begin{aligned}
 T(n) &\leq \mathcal{C}n + T(\lfloor \frac{n}{5} \rfloor) + T(\lfloor 0,7n \rfloor + 3) \\
 &\leq \mathcal{C}n + \mathcal{C}'\frac{n}{5} + \mathcal{C}' * 0,7n + \mathcal{C}'3 \\
 &\leq \mathcal{C}'\frac{n}{20} \\
 &\leq \mathcal{C}'n(0,05 + 0,2 + 0,7) + \mathcal{C}' \cdot 3 \\
 &= \mathcal{C}'(0,95n + 3) \leq \mathcal{C}'n \\
 0,95n + 3 &\leq n \\
 3 &\leq n \cdot 0,05 \quad (n \geq 100 \rightarrow n \cdot 0,05 \geq 5)
 \end{aligned}$$